



Relatório Semanal — ArXiv Monitor

Extração, Classificação e Quantificação de Artigos Científicos

Período: 2026-07-04 a 2026-07-11

11 de July de 2026

Versão 1.0

Resumo. Este relatório apresenta a análise semanal de artigos científicos publicados no arXiv nas categorias de Inteligência Artificial (cs.AI), Machine Learning (cs.LG), Processamento de Linguagem Natural (cs.CL) e Visão Computacional (cs.CV). Foram extraídos ****100**** artigos via API, classificados por um LLM (Claude Haiku) com saída estruturada (Pydantic), dos quais ****90**** (90.0%) foram identificados como relevantes para aplicações de negócios. A classificação avaliou área tecnológica, maturidade e relevância de cada artigo, seguindo a metodologia CRISP-DM.

Palavras-chave: arXiv; Artigos Científicos; LLM; Saída Estruturada; CRISP-DM.

1 Resumo

Este relatório semanal analisa artigos científicos publicados no arXiv nas categorias de Inteligência Artificial, Machine Learning, Processamento de Linguagem Natural e Visão Computacional. O pipeline automatizado extrai, classifica e gera um relatório executivo para tomadores de decisão, seguindo a metodologia CRISP-DM.

2 Metodologia

Seguindo o fluxo **CRISP-DM**: (i) *entendimento do negócio* — identificar artigos relevantes para aplicações de negócios em IA/ML/NLP/CV; (ii) *dados* — API pública do arXiv, período de 2026-07-04 a 2026-07-11; (iii) *preparação* — extração com retry e filtragem por data; (iv) *modelagem* — classificação via Claude Haiku com schema Pydantic; (v) *avaliação* — análise estatística dos resultados; (vi) *implantação* — este paper reproduzível.

3 Dados

3.1 Parâmetros da extração

A extração foi realizada utilizando a API pública do arXiv com os seguintes parâmetros:

- **URL base:** <https://export.arxiv.org/api/query>
- **Período:** últimos 7 dias (2026-07-04 a 2026-07-11)
- **Categorias de busca:**
 - cs.AI
 - cs.LG
 - cs.CV
 - cs.CL
 - cs.HC
 - stat.ML
 - cs.RO
 - cs.SD
 - cs.SE
 - cs.CY
 - cs.IR
 - cs.DC
 - cs.NI
 - cs.AR
 - math.NA
 - math.PR
 - cs.DS
 - cs.GR
 - cs.PL
 - eess.SP

- cs.MA
- math.SP
- q-bio.NC
- cs.DB
- cs.IT
- math.ST
- q-bio.QM
- cs.CR

- **Ordenação:** por data de submissão (decrecente)
- **Limite por página:** 100 artigos

3.2 Schema de classificação

Cada artigo foi classificado com o seguinte schema Pydantic:

```
from pydantic import BaseModel, Field
from typing import Literal

class ArtigoClassificado(BaseModel):
    arxiv_id: str = Field(description="ID do artigo no arXiv")
    titulo_pt: str = Field(description="Título traduzido para o português")
    area_tecnologica: str = Field(description="Área tecnológica principal")
    resumo_executivo_pt: str = Field(description="Resumo executivo em português")
    maturidade: Literal["pesquisa_basica", "pesquisa_aplicada", "prototipo", "producao"]
    relevancia_negocio: Literal["baixa", "media", "alta", "critica"]
    justificativa: str = Field(description="Justificativa da relevância para negócios")

print("Schema definido com sucesso!")
```

Schema definido com sucesso!

4 Resultados

4.1 Resumo da extração

A Tabela Tabela 1 apresenta um resumo dos dados extraídos e classificados.

4.2 Distribuição por categoria arXiv

A Tabela Tabela 2 mostra a distribuição de artigos por categoria arXiv.

4.3 Distribuição por área tecnológica

A Tabela Tabela 3 apresenta a distribuição por área tecnológica identificada pelo LLM.

Tabela 1: Resumo da extração.

Indicador	Valor
Total de artigos	100
Período	2026-07-04 a 2026-07-11
Relevantes	90 (90.0%)
Categorias arXiv	28
Áreas tecnológicas	8
Custo estimado	\$0.0200

Fonte: API do arXiv, processado por LLM (Claude Haiku, temperature=0).

Tabela 2: Distribuição por categoria arXiv.

Categoria	Quantidade
cs.AI	44
cs.LG	42
cs.CV	31
cs.CL	18
cs.HC	5
stat.ML	4
cs.RO	4
cs.SD	2
cs.SE	2
cs.CY	2
cs.IR	2
cs.DC	2
cs.NI	2
cs.AR	2
math.NA	1
math.PR	1
cs.DS	1
cs.GR	1
cs.PL	1
eess.SP	1
cs.MA	1
math.SP	1
q-bio.NC	1
cs.DB	1
cs.IT	1
math.ST	1
q-bio.QM	1
cs.CR	1

Fonte: API do arXiv, processado por LLM (Claude Haiku, temperature=0).

Tabela 3: Distribuição por área tecnológica.

Área Tecnológica	Quantidade
LLM	29
Visão Computacional	24
IA Generativa	22
MLOps	11
Aprendizado por Reforço	6
Segurança em IA	4
Outra	3
Robótica	1

Fonte: API do arXiv, processado por LLM (Claude Haiku, temperature=0).

Tabela 4: Distribuição por maturidade tecnológica.

Maturidade	Quantidade
pesquisa_aplicada	80
pesquisa_basica	5
producao	3
prototipo	12

Fonte: API do arXiv, processado por LLM (Claude Haiku, temperature=0).

4.4 Distribuição por maturidade

A Tabela Tabela 4 mostra o nível de maturidade tecnológica dos artigos.

4.5 Top 5 artigos por relevância

A Tabela Tabela 5 apresenta os 5 artigos com maior relevância para negócios.

4.6 Evolução diária

A Figura Figura 1 mostra a distribuição de publicações por dia no período analisado.

Tabela 5: Top 5 artigos por relevância para negócios.

#	Título	Área	Relevância
1	AUTOPILOT VQA: Avaliação de Modelos Visão-Linguagem para Com	Visão Computacional	critica
2	HumanForge: Um Benchmark de Vídeo Deepfake Centrado em Human	Visão Computacional	critica
3	MPFlow: Aprendizado de Otimização de Fluxo Máximo com Orçame	Aprendizado por Reforço	critica
4	As Transformações Revelam a Verdade? Aprendizado de Resíduos	Visão Computacional	critica
5	UltraX: Refinamento de Dados de Pré-Treinamento em Escala co	LLM	critica

Fonte: API do arXiv, processado por LLM (Claude Haiku, temperature=0).

Tabela 6: Custo estimado da classificação.

Métrica	Valor
Total de tokens	80,000
Custo por artigo	\$0.000200
Custo total	\$0.0200

Estimativa baseada em 800 tokens por artigo (input + output). Preço Claude Haiku 4.5: \$0.25/1M tokens.




Figura 1: Publicações por dia no período analisado.

4.7 Custo estimado

A Tabela Tabela 6 apresenta a estimativa de custo da classificação via API Anthropic.

5 Lista de Artigos

5.1 Todos os artigos

A Tabela Tabela 7 lista todos os artigos extraídos e classificados no período.

6 Conclusão

Foram extraídos **100** artigos do arXiv no período de 2026-07-04 a 2026-07-11, classificados por um LLM com saída estruturada. Destes, **90** (90.0%) foram identificados como relevantes para

Tabela 7: Todos os artigos extraídos no período.

Data	Título	Área	Maturidade	Relev.	Resumo
2026-07-09	Wat3R: Aprendizado de Geometria 3D	Visão Computacional	pesquisa_aplic	alta	Wat3R é um framework de aprendizado semi-supervisionado
2026-07-09	ZipDepth: Levando Estimativa de Pro	Visão Computacional	prototipo	alta	ZipDepth é uma rede compacta de estimativa de profundidade
2026-07-09	LongE2V: IA Generativa Reconstrução, Predição e I	Visão Computacional	pesquisa_aplic	alta	LongE2V é uma abordagem inovadora que utiliza modelos de
2026-07-09	Particionamento Baseado em Geometria	Visão Computacional	pesquisa_aplic	alta	O artigo apresenta PanoLOG, um framework de reconstrução
2026-07-09	UniClawBench: Um Benchmark Universal	Visão Computacional	pesquisa_aplic	alta	UniClawBench é o primeiro benchmark orientado por
2026-07-09	OPSD-V: Auto-Destilação em Política	Visão Computacional	pesquisa_aplic	alta	OPSD-V é um paradigma de auto-destilação em política
2026-07-09	Aprimorando	Visão Computacional	pesquisa_aplic	alta	Canvas360

aplicações de negócios. O pipeline automatizado — extração via API, classificação por LLM com schema Pydantic e geração do relatório — demonstra a viabilidade de monitorar o arXiv com foco em oportunidades de negócio, seguindo a metodologia CRISP-DM.

O custo estimado da classificação foi de **\$0.0200**, tornando o processo viável para operações semanais.

7 Referências